

Влияние искусственного выравнивания частот токенов на разрыв в производительности между Adam и SGD

Выдрина Ксения, Новокшонова Анна, Чайкин Владимир, Чернобай Андрей
Optimization Class Project. MIPT

Введение

Многочисленные эксперименты показывают, что оптимизатор Adam значительно превосходит стохастический градиентный спуск (SGD) при обучении языковых моделей, тогда как на задачах компьютерного зрения разрыв минимален. Согласно гипотезе [1], ключевая причина является дисбаланс классов с «тяжёлыми хвостами» - ситуация, когда редкие по частоте классы составляют большую долю данных, естественным образом возникающая в текстах из-за закона Ципфа. В данном проекте мы искусственно выравниваем эмпирическое распределение токенов в обучающем корпусе и сравниваем сходимость Adam и SGD на исходном и выровненном данных. Ожидается, что устранение дисбаланса приведёт к сокращению разрыва между оптимизаторами, что станет дополнительным подтверждением выдвинутой гипотезы.

Постановка задачи

Дан обучающий корпус $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, состоящий из n пар “контекст $\mathbf{x}_i \in \mathcal{X}$ – целевой токен $y_i \in 1, \dots, c$ ”, а также модель $f_{\boldsymbol{\theta}} : \mathcal{X} \rightarrow \mathbb{R}^c$.

Ставится задача минимизация эмпирического риска для многоклассовой классификации:

$$\min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \ell(\boldsymbol{\theta}, \mathbf{x}_i, y_i), \quad \ell(\boldsymbol{\theta}, \mathbf{x}, y) = -\log \frac{e^{[f_{\boldsymbol{\theta}}(\mathbf{x})]_y}}{\sum_{j=1}^c e^{[f_{\boldsymbol{\theta}}(\mathbf{x})]_j}}$$

Дисбаланс классов с «тяжёлыми хвостами»

Частота класса k :

$$\pi_k = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[y_i = k], \quad k = 1, \dots, c.$$

В типичном текстовом корпусе распределение $\{\pi_k\}_{k=1}^c$ обладает свойством «тяжёлых хвостов», т. е. немногие классы (наиболее частотные токены) имеют вероятность $\pi_k \gg 1/c$, а большинство классов (редкие токены) имеют вероятность $\pi_k \ll 1/c$, и при этом суммарный вклад редких классов в общее число примеров значителен.

Метрики

Для проверки гипотезы измеряем два класса величин: равномерность распределения токенов в обучающем корпусе после токенизации и качество сходимости оптимизаторов SGD и Adam.

Равномерность

Нормализованная энтропия: $H_{\text{norm}} = -\frac{1}{\log V} \sum_k \pi_k \log \pi_k \in [0, 1]$, где V — словарь, π_k — частота токена k . $H_{\text{norm}}=1$: равномерное использование словаря; $\rightarrow 0$: концентрация на немногих токенах.

Коэффициент Джини: дополнительная мера неравенства частот $\{\pi_k\}$.

Доля топ- N : $S_N = \sum_{k=1}^N \pi_{(k)}$, $N \in \{10, 100\}$ — прямая интерпретация «тяжести хвоста».

Оптимизация

Финальные потери $\mathcal{L}_{\text{SGD}}^{(T)}$, $\mathcal{L}_{\text{Adam}}^{(T)}$.

Разрыв $\Delta = \mathcal{L}_{\text{SGD}}^{(T)} - \mathcal{L}_{\text{Adam}}^{(T)}$.

Минимум $\min_t \mathcal{L}^{(t)}$ — устойчив к колебаниям SGD.

Токенизация

BPE 50k и 5k

Byte Pair Encoding [2], обученный с нуля на нашем корпусе. Варьирование V показывает влияние размера словаря.

Subsampling

BPE 50k с частотным прореживанием потока токенов [3]: каждое вхождение токена сохраняется с вероятностью $p_k = \min\{1, \sqrt{t/\pi_k}\}$, $t = 10^{-5}$.

Unigram 30k и 10k

Алгоритм [4] строит словарь, оптимизируя правдоподобие корпуса и удаляя наименее полезные под слова. Распределение частот заметно ровнее, чем у BPE; варьирование V показывает влияние размера словаря.


Unigram 5k + регуляризация

То же с $V = 5,000$, но при кодировании разбиение слова не фиксированное, а *сэмплируется* из распределения $P(\cdot)^\alpha$, $\alpha = 0.1$. Один и тот же текст разбивается по-разному — в обучении задействуется больше токенов словаря.

Вычислительный эксперимент

Данные

Новостной корпус на русском языке (LLMTrace). Для иллюстрации неравномерности использования словаря — распределение частот топ-100 токенов для BPE 5k:



Модель

GPT-2 [5], обучаемая с нуля.

Параметры обучения

Для каждой схемы токенизации модель обучается дважды — с SGD ($\eta = 0.5$) и Adam ($\eta = 10^{-3}$). Зафиксированы batch = 32, кросс-энтропийная функция потерь, отсечение нормы градиента $\|\nabla\| \leq 1$.

Этапы

Промежуточный эксперимент: $n_{\text{embd}} = 256$, 4 слоя, 4 головы внимания, длина контекста 128, $T = 10$ эпох. Оценка эффекта на полноразмерной модели.


Основной эксперимент (в процессе): уменьшенная архитектура ($n_{\text{embd}} = 128$, 2 слоя, 2 головы, контекст 64) при $T = 100$ эпохах. Сравнение оптимизаторов после выхода на плато.

Результаты промежуточного этапа

Эксперимент	$\mathcal{L}_{\text{SGD}}^{(T)}$	$\mathcal{L}_{\text{Adam}}^{(T)}$	Δ
Базовый BPE 50k	6.35	5.54	0.81
Subsampling	9.74	8.55	1.18
BPE 5k	5.40	5.27	0.13
Unigram 30k	6.08	5.63	0.45
Unigram 10k	5.62	5.39	0.23
Unigram 5k + reg	4.15	4.06	0.09

Основной эксперимент

Для углублённого анализа на $T = 100$ эпохах выбраны четыре схемы: *BPE 50k* (baseline, обучен на $T = 50$ эпохах), *BPE 5k*, *BPE 5k с обрезкой топ-10 токенов* и *Unigram 5k + reg*.



Метрики основного этапа

Метрика	BPE 50k	BPE 5k	BPE 5k + обрезка	Unigram 5k + reg
H_{norm}	0.7740	0.8528	0.8199	0.8083
Gini	0.9943	0.6849	0.6876	0.7544
S_{10}	0.1786	0.1333	0.1713	0.1853
S_{100}	0.3198	0.3439	0.3575	0.4355
$\mathcal{L}_{\text{SGD}}^{(T)}$	6.35	5.7052	5.5690	4.4782
$\mathcal{L}_{\text{Adam}}^{(T)}$	5.54	5.6662	5.5332	4.4467
Δ	0.81	0.0390	0.0358	0.0315
$\min_t \mathcal{L}_{\text{SGD}}^{(t)}$	6.35	5.7052	5.5690	4.4782
$\min_t \mathcal{L}_{\text{Adam}}^{(t)}$	5.54	5.6662	5.5332	4.4467

Заключение

Как видно по результатам вычислительного эксперимента, выравнивание распределения токенов сокращает разрыв в производительности между Adam и SGD, что подтверждает исследуемую гипотезу. Для baseline токенизации итоговая разница лоссов составила 0.81, в то время как для BPE 5k, BPE 5k + обрезка и Unigram 5k + reg - 0.0390, 0.0358 и 0.0315 соответственно. При этом видно, что энтропия у этих токенизаций где-то на 0.03 больше, а коэффициент Джини - на 0.24 – 0.31 ниже, что говорит о более равномерном распределении токенов.

Таким образом, в ходе проекта удалось подтвердить теорию о роли дисбаланса классов с «тяжёлыми хвостами» в разрыве в производительности между Adam и SGD в пользу первого. И хоть разрыв все еще остается, в силу того, что исследованный фактор не является единственной причиной превосходства Adam, более равномерная токенизация позволяет заметно его снизить.

Литература

- [1] Frederik Kunstner, Robin Yadav, Alan Milligan, Mark Schmidt, and Alberto Bietti. Heavy-tailed class imbalance and why adam outperforms gradient descent on language models, 2024.
- [2] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pages 1715–1725, 2016.
- [3] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg Corrado, and Jeffrey Dean. Distributed representations of words and phrases and their compositionality. In *Advances in Neural Information Processing Systems*, volume 26, 2013.
- [4] Taku Kudo. Subword regularization: Improving neural network translation models with multiple subword candidates. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, pages 66–75, 2018.
- [5] Alec Radford, Jeffrey Wu, Rewon Luan, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. *OpenAI Technical Report*, 2019.